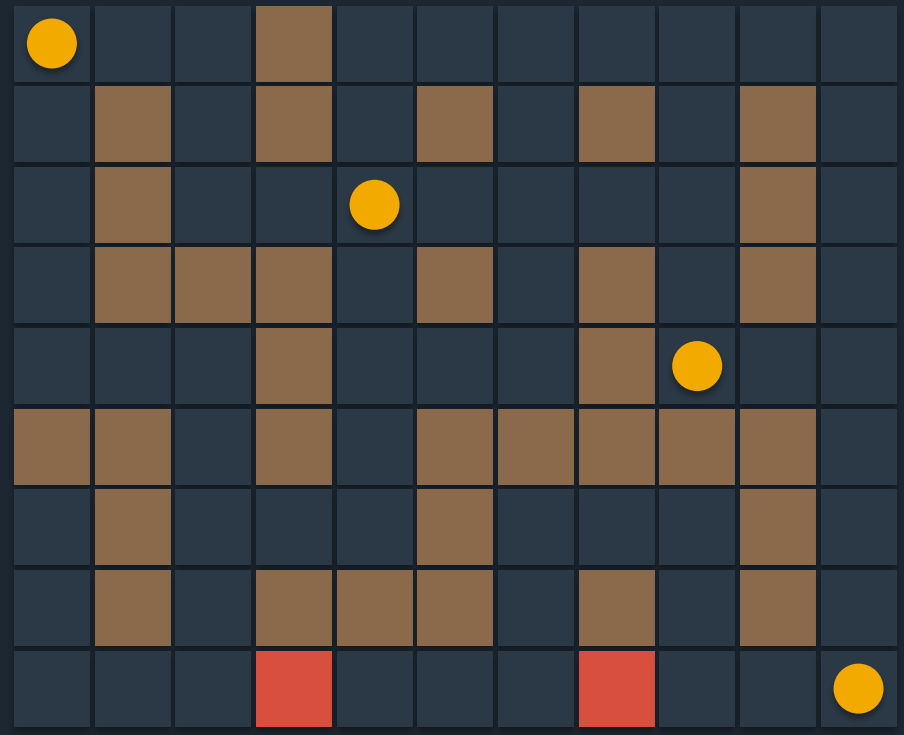
PROJET D'APPRENTISSAGE PAR RENFORCEMENT

Coordonner une flotte de robots d'entrepôt

Du Q-learning tabulaire au PPO centralisé

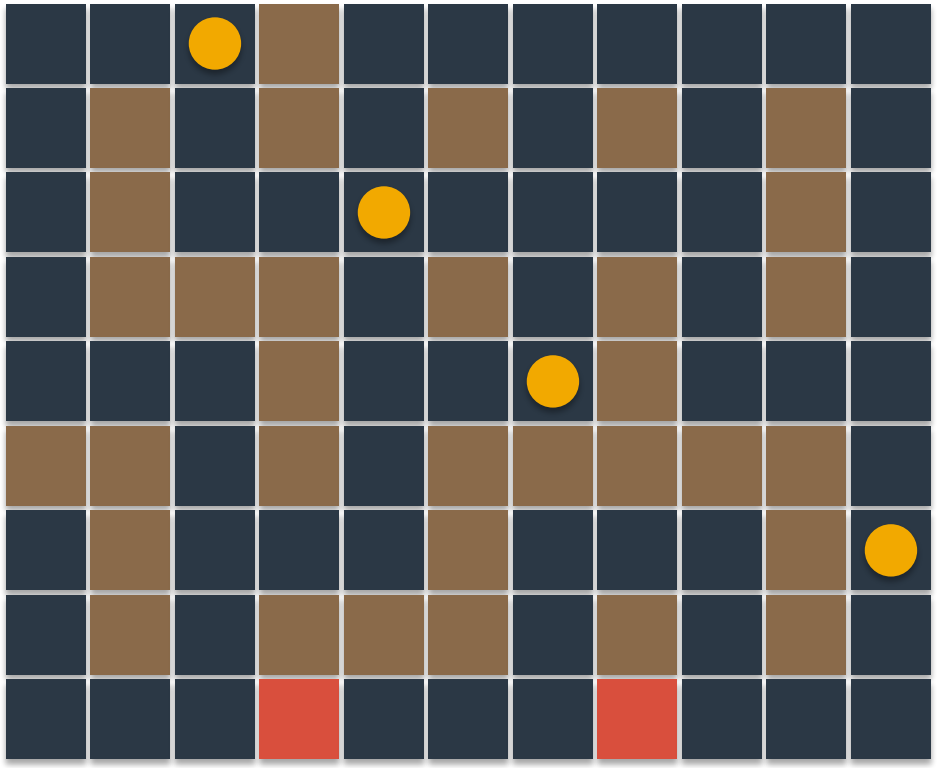


Antoine de Chabannes · Lohann Colle · Juliette Girardin · Loïc Lamour

Master 2 · Université Côte d'Azur

LE PROBLÈME

Livrer sans se bloquer dans des allées d'une case



étagère quai robot

1 **Prélever**

étagère ⟶ quai, ou ranger : quai ⟶ étagère

2 **Naviguer**

labyrinthe nouveau à chaque épisode, humains qui errent

3 **Se coordonner**

allées d'une case : deux robots face à face se bloquent

Un environnement à difficulté réglable

Actions

- 6 actions discrètes
- prendre / déposer face à la cible
- pas d'attente : on tourne sur place

Observation

- position, orientation, mission
- 4 rayons : mur, étagère, robot, humain
- les autres ne sont vus que par les rayons

Récompense

- +10 par livraison
- −0,05 par pas, −1 si bloqué
- 50 % propre, 50 % moyenne de flotte

Scénarios de référence

basic	carte 7×6 fixe, sans facteur
hard	labyrinthe 11×9, 4 robots, 2 humains, priorités, robots lents
big	labyrinthe 21×21, 6 robots, 3 humains, tout activé, 400 pas

PROTOCOLE

Une courbe d'entraînement n'est pas un résultat

100

épisodes par chiffre rapporté

à 20, le glouton passe de 5,00 à 6,23 : bruit

0

carte commune entre entraînement et évaluation

le lanceur refuse de démarrer sinon

3000

épisodes « appris » par erreur

c'était le professeur qui livrait

On rapporte d'abord les livraisons et les actions invalides, puis les blocages ; le retour moyen a un plancher indépendant de la politique.

MÉTHODES

Cinq façons de décider, du tabulaire au planificateur

1

Glouton

BFS à chaque pas, ε = 0,1

RÉFÉRENCE

2

Q-table centralisée

une table, 6^n actions jointes

TABULAIRE

3

Q-learning indépendant

une table par robot

TABULAIRE

4

PPO centralisé

masqué, encodeur par paires

PROFOND

5

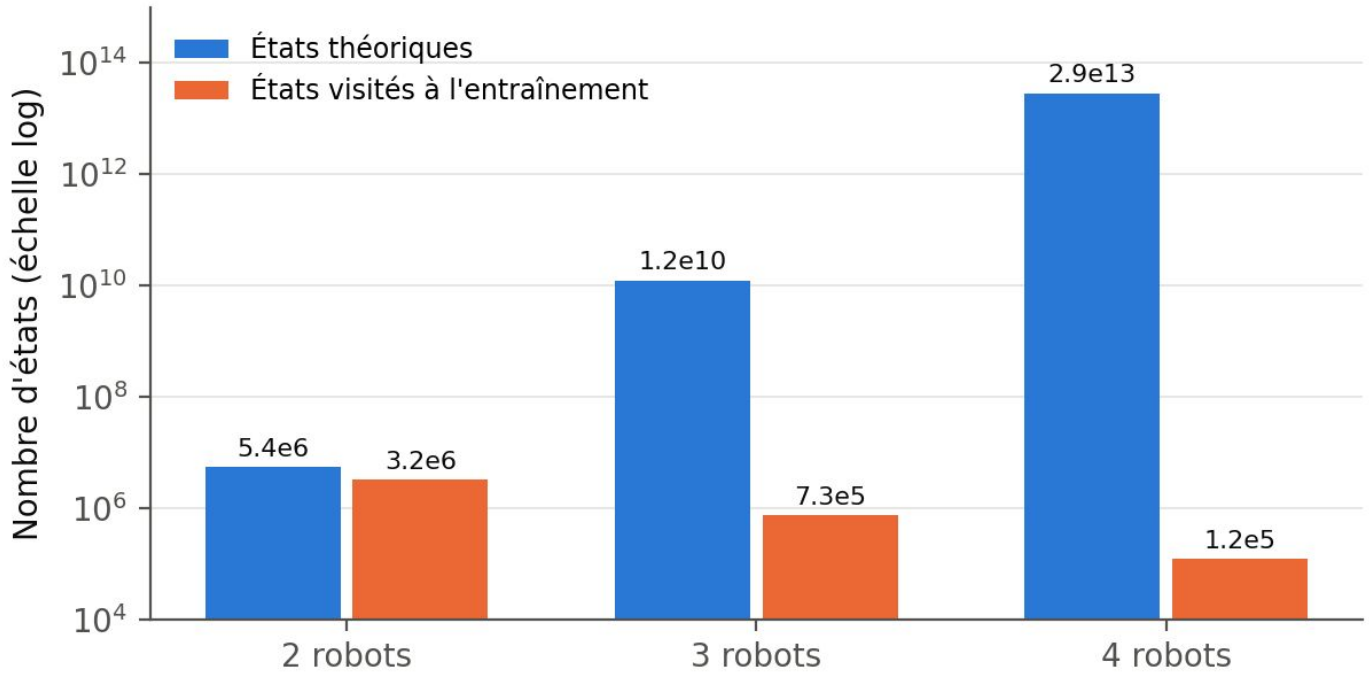
Planificateur

réservations espace-temps

NON APPRIS

Toutes les méthodes passent par la même interface et les mêmes tests (183) : seul l'algorithme change.

Q-table centralisée : la taille explose avec la flotte

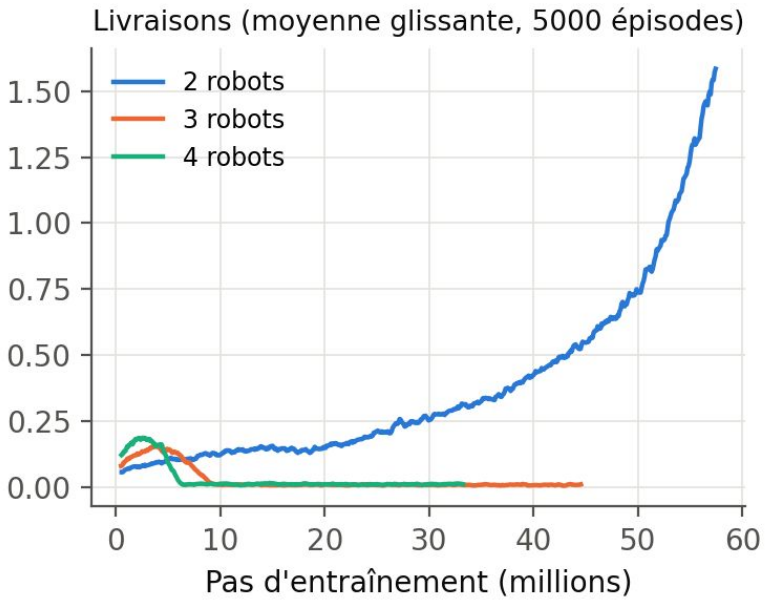


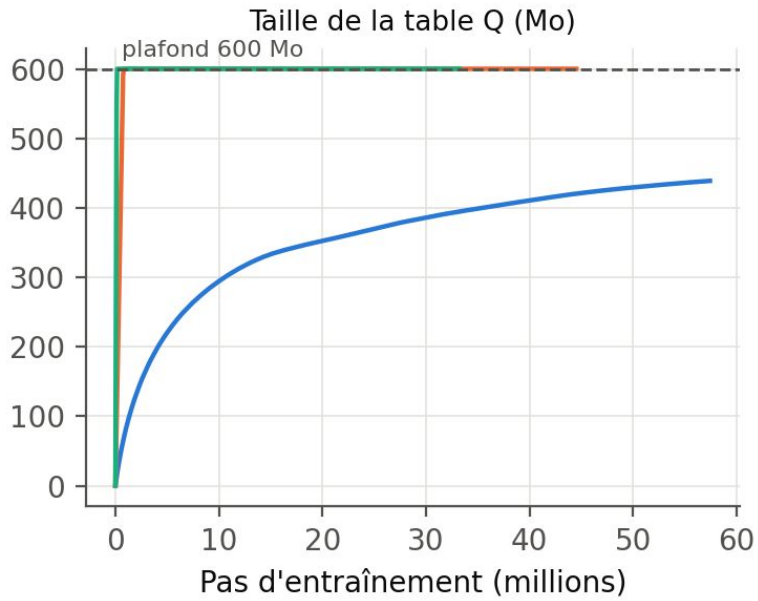
actions jointes · états théoriques

2 robots	**36**	$5{,}4 \cdot 10^{6}$
3 robots	**216**	$1{,}2 \cdot 10^{10}$
4 robots	**1 296**	$2{,}9 \cdot 10^{13}$

6^n actions × $(34 \cdot 4 \cdot 17)^n$ états : la mémoire sature avant l'apprentissage.

À 3 robots, la table est pleine en un million de pas





- **2 robots :** 1,2 livraison/épisode après 57 M de pas
- **3–4 robots :** plafond 600 Mo atteint, 98–99,6 % des mises à jour rejetées
- **En évaluation :** 99,5–100 % des états jamais vus

PPO : quatre choix mesurés font la différence

Masquer les actions

actions invalides par épisode

1128 → 0

Distances BFS

dimensions d'entrée, et la carte n'entre plus dans le réseau

882 → 5

Signal de collision

blocages par épisode

45,2 → 12,6

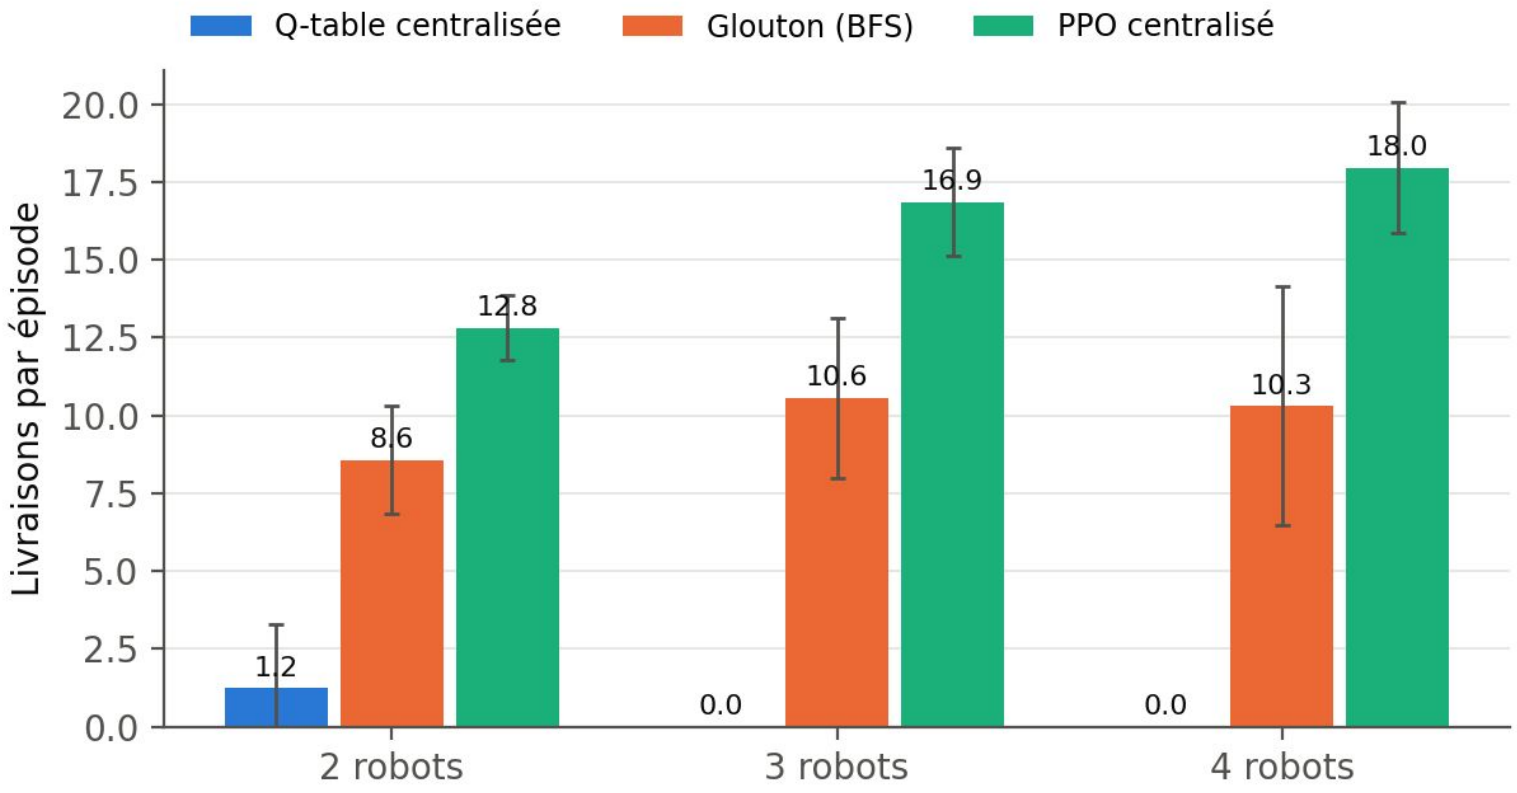
Échantillonner

blocages par interblocage miroir

211 → ≈ 0

Architecture : un seul réseau lit toute la flotte ; pour chaque robot, un encodeur compare chaque paire (i, j), agrégée par max (« une menace ? ») et moyenne (« encombré ? »). On-policy, sans schedule.

PPO bat le glouton partout, la Q-table s'effondre



+50 %

PPO vs glouton, 2 robots

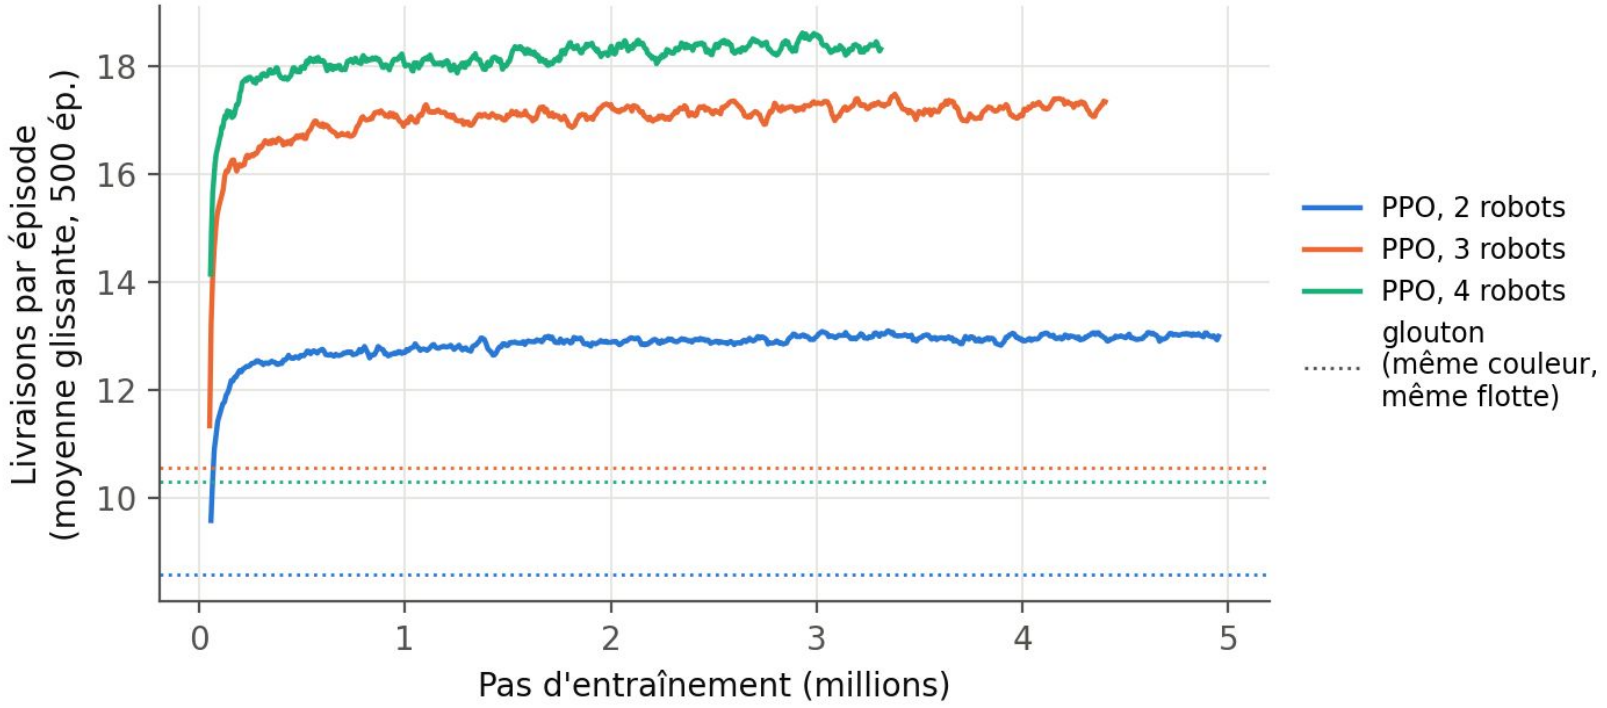
+74 %

PPO vs glouton, 4 robots

0

livraison Q-table dès 3 robots

PPO atteint son plateau en moins d'un million de pas



- Entrées indépendantes de la carte et de n : généralise aux états jamais vus
- 60 min par taille, ≈ 1 400 pas/s sur CPU
- Pointillés : glouton avec la même flotte

Sur le scénario le plus dur, PPO livre 73 % de plus

	Livraisons	Job ratio	Retours arrière
Glouton	10,6	2,12	0,340
PPO (12 h)	**18,3**	**1,50**	**0,081**

- **Le glouton oscille :** un tiers de ses pas reviennent sur la case quittée
- **PPO attend en tournant :** 98,5 % de ses demi-tours sont près d'un autre agent
- **Une action WAIT** accélère l'apprentissage mais crée des interblocages en évaluation

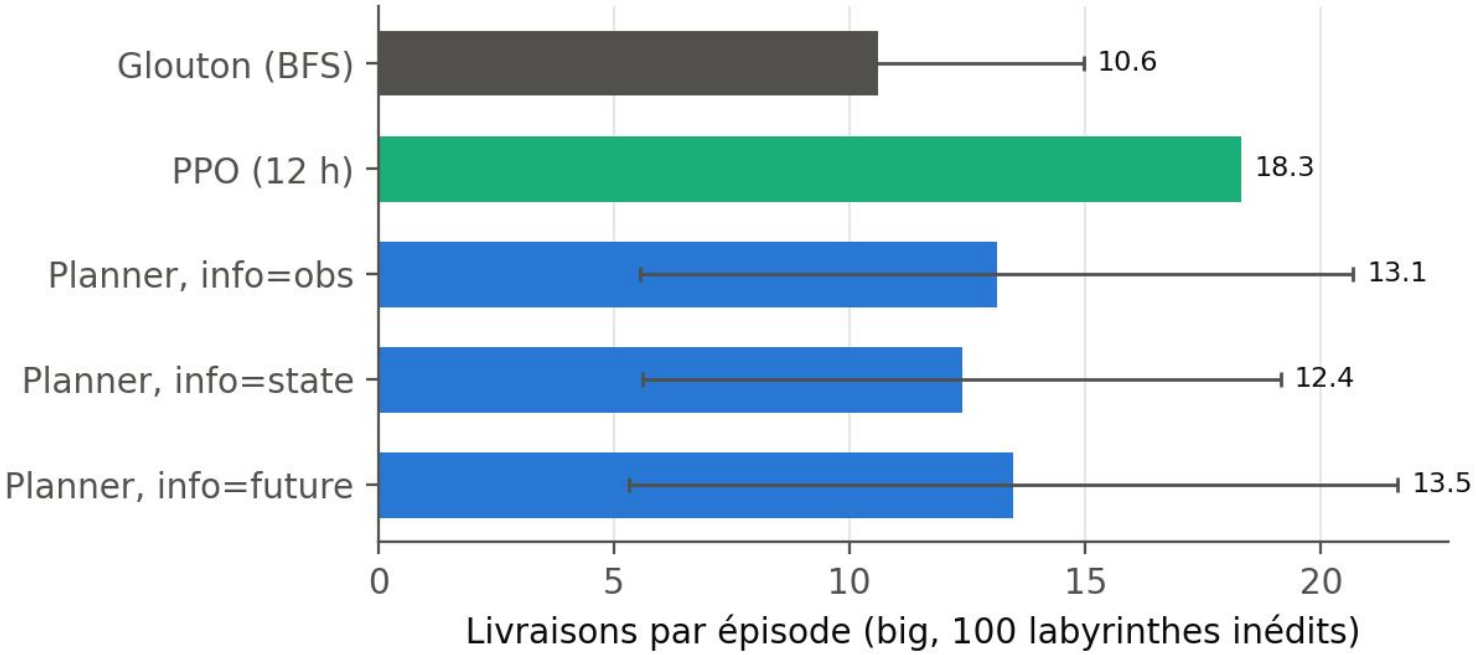
18,3

livraisons par épisode

10,6

pour le glouton

Zéro collision ne veut pas dire plus de livraisons



- **0 blocage,** trajets les plus directs, mais 13,1 livraisons contre 18,3
- **Voir les humains,** même leur futur : 12,4 à 13,5, dans le bruit
- **PPO a appris** à partager les couloirs
- **search :** à compléter (Lohann)

Ce qu'on retient

1

Le tabulaire centralisé ne passe pas à l'échelle

la mémoire sature avant l'apprentissage ; aveugle sur 99,5 % des états dès 3 robots

2

PPO généralise

entrées indépendantes de la carte et de la flotte ; +74 % sur le glouton à 4 robots, 18,3 contre 10,6 sur big

3

Les choix mesurés comptent plus que l'algorithme

masquer, donner les distances BFS, façonner sans flânerie, évaluer sur cartes inédites

Pistes : VDN / QMIX, têtes autorégressives, caractéristiques vectorisées

PARTIE 02

Multi-Agent Reinforcement Learning

IQL Tabulaire

IDQN (Masquage 11D)

IPPO & MAPPO

Multi Agent Reinforcement Learning Décisions

Actions

- 6 actions discrètes
- prendre / déposer face à la cible
- pas d'attente : on tourne sur place

Observation

- position, orientation, mission
- 4 voisins: mur, étagère, robot, humain

Récompense

- +10 par livraison
- −0,05 par pas, −1 si bloqué
- 50 % propre, 50 % moyenne de flotte

Scénarios de référence

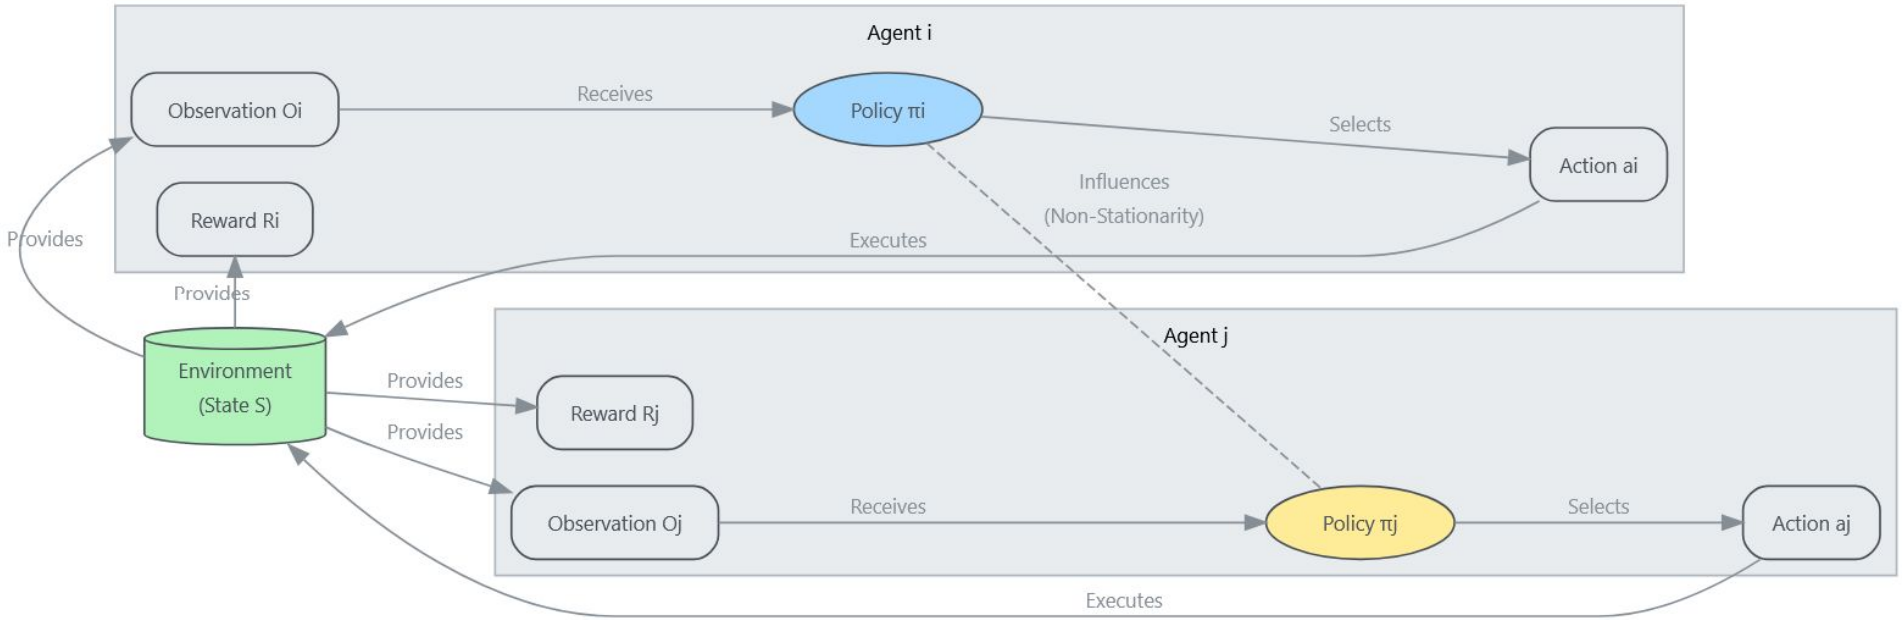
basic	carte 7×6 fixe, sans facteur
hard	labyrinthe 11×9, 4 robots, 2 humains, priorités, robots lents
big	labyrinthe 21×21, 6 robots, 3 humains, tout activé, 400 pas

Multi Agent Systems

Définition

- Un environment : l'espace ou contexte dans lequel les agents évoluent
- Plusieurs agents : décideurs autonomes, qui perçoivent chacun l'environnement et choisissent des actions pour atteindre leurs objectifs
- Des interactions : les actions d'un agent peuvent influencer l'état de l'environnement

Problématiques pour Multi Agent Reinforcement Learning : non-stationnarité



https://apxml.com/courses/advanced-reinforcement-learning/chapter-6-multi-agent-reinforcement-learning

Multi Agent Reinforcement Learning

Non-Stationnarité

Single-Agent:

Un seul agent qui évolue dans un l'environnement.

L'environnement reste le même pour l'agent.

L'environnement est stationnaire.

Multi-Agent:

Plusieurs agents évoluent dans un l'environnement.

Pour chaque agent :

- Les autres agents font partie de l'environnement
- Sa policy et son comportement évolue
- Il réalise des actions

Les agents voient leur environnement évoluer, l'environnement n'est pas stationnaire.

Multi Agent Reinforcement Learning (MARL)

IQL Tabulaire (Independent Q-Learning)

- Indépendant
- Q-Learning Standart

IDQN (independent DQN)

- Indépendant
- Deep Q-Learning (utilise un Deep Neural Network pour apprendre la Q-table)

IPPO (Independent Proximal Policy Optimization)

- Indépendant
- Policy Gradient
- Actor-Critic
- PPO

skrl

MAPPO (Multi-Agent Proximal Policy Optimization)

- Centralisé pendant l'entraînement
- Décentralisé pendant l'exécution
- Policy Gradient (Actor)
- Critique centralisée (Critic)
- PPO

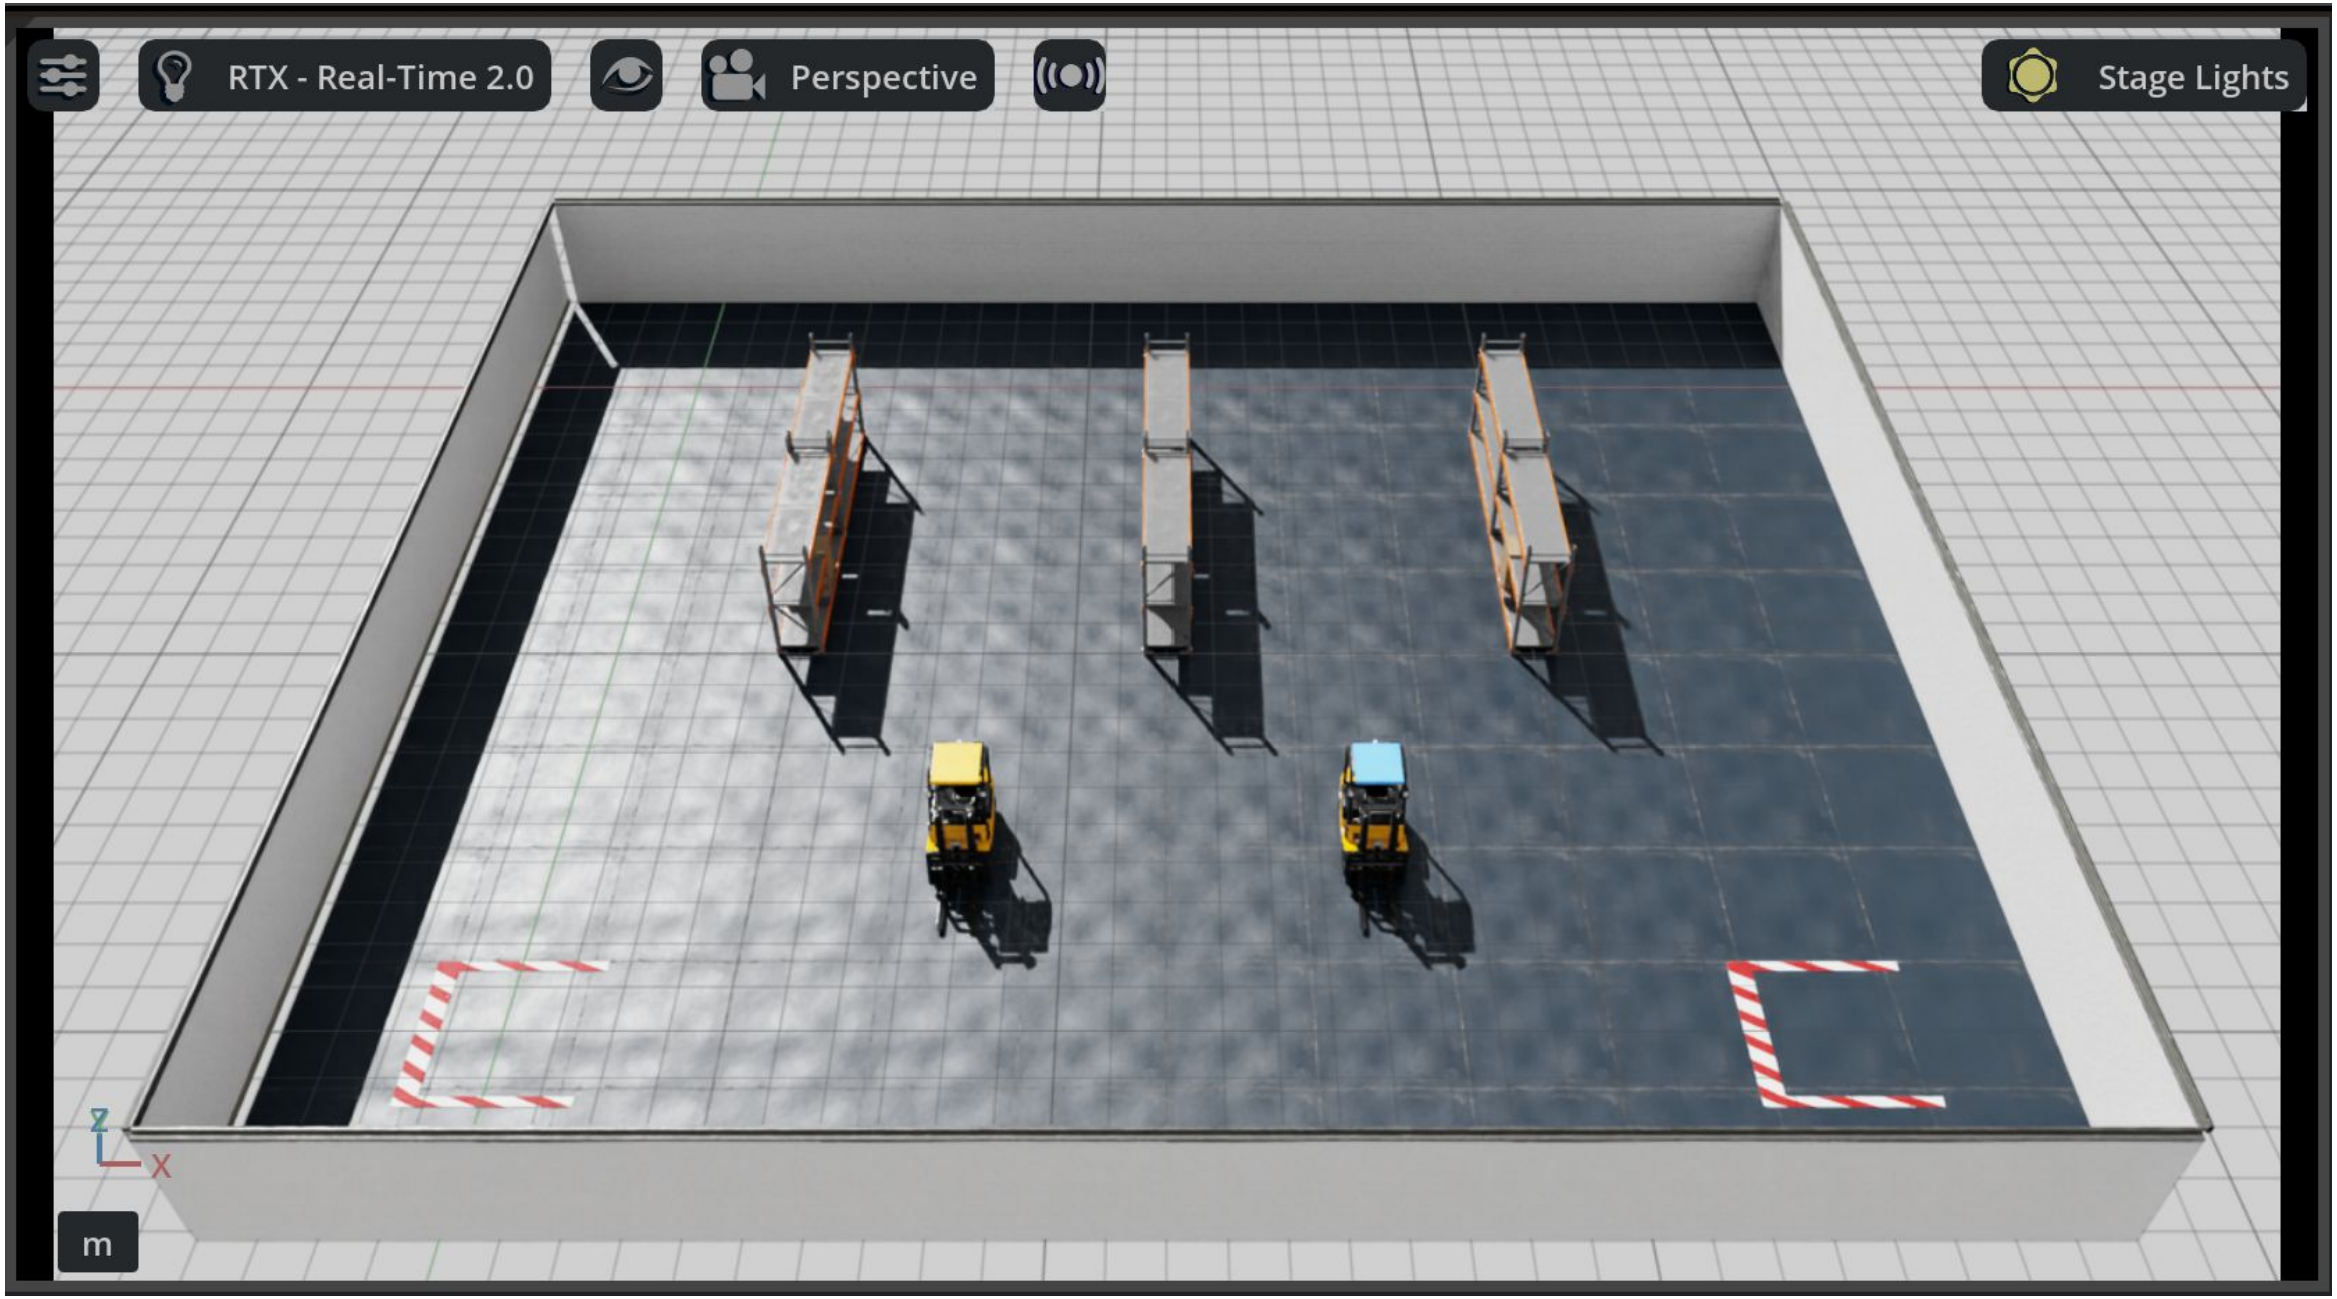
skrl

Algorithm 1 PPO, Actor-Critic Style

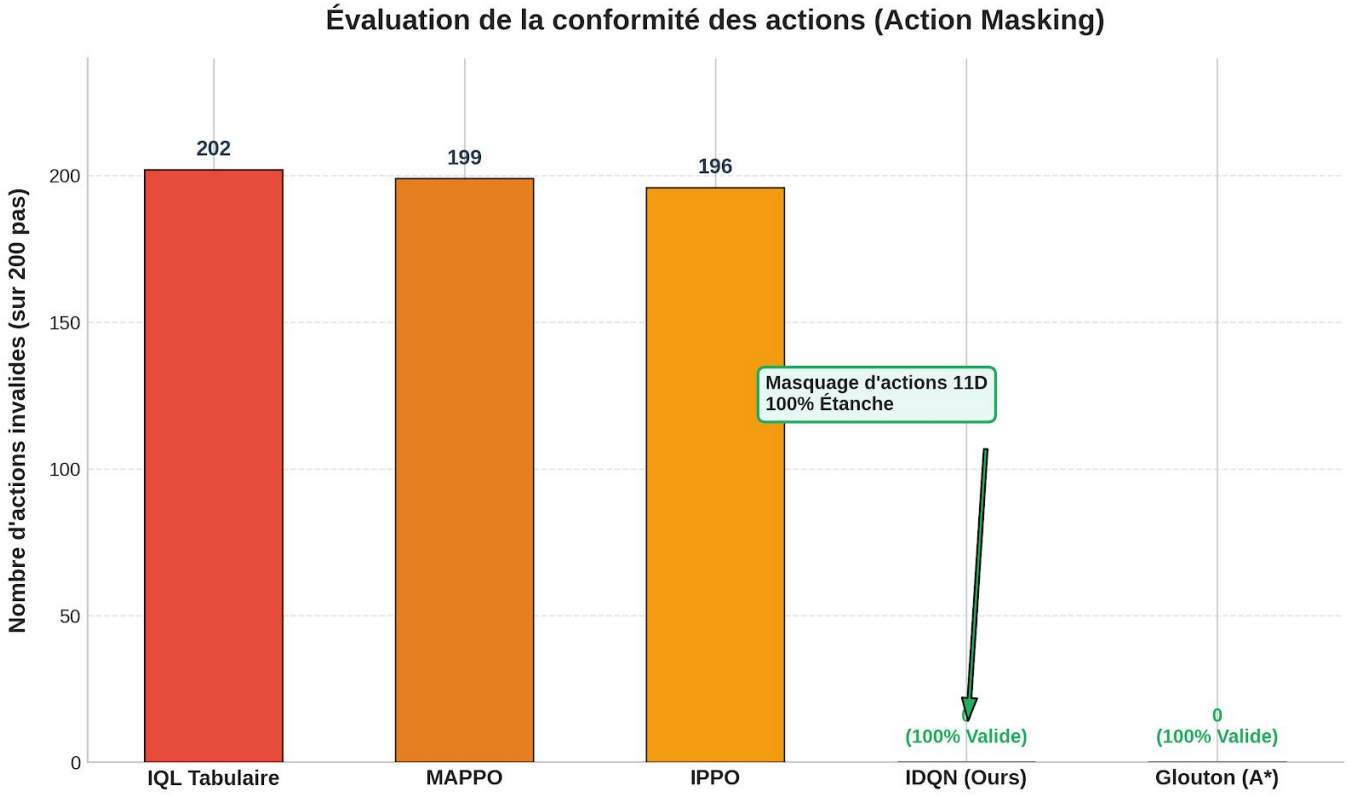
for iteration=$1, 2, \ldots$ **do**
  for actor=$1, 2, \ldots, N$ **do**
    Run policy $\pi_{\theta_{\text{old}}}$ in environment for T timesteps
    Compute advantage estimates $\hat{A}_1, \ldots, \hat{A}_T$
  end for
  Optimize surrogate L wrt θ, with K epochs and minibatch size $M \leq NT$
  $\theta_{\text{old}} \leftarrow \theta$
end for

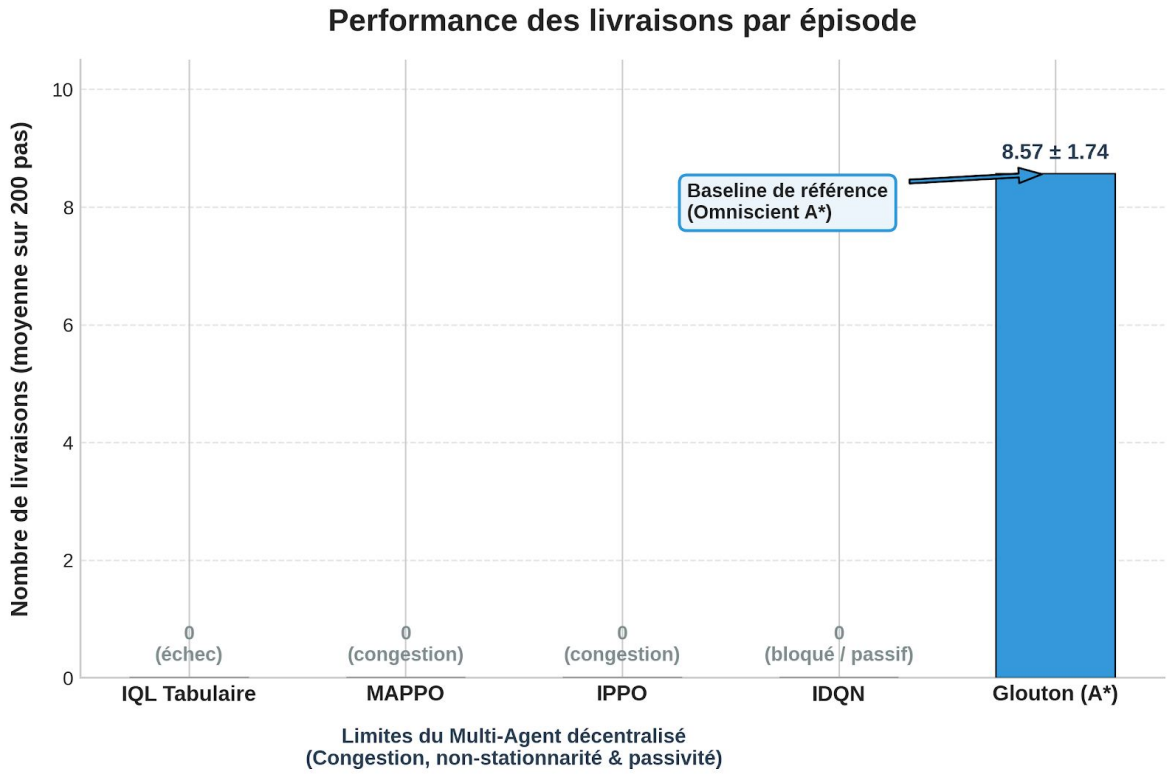
https://arxiv.org/abs/1707.06347

IDQN



Comparaison : actions invalides et livraisons





RÉSULTATS & DIAGNOSTIC · APPROCHE DÉCENTRALISÉE

Pourquoi 0 Livraison & Actions Invalides ?

Analyse comparative des mécanismes de défaillance et des verrous d'apprentissage multi-agents.

Saturation Mémoire

IQL Tabulaire

Q-learning indépendant sans masquage

ACTIONS INVALIDES
~202
Aucun filtre applicatif.

ESPACE D'ÉTATS
2 × 10⁹ configurations
Labyrinthe 21×21 inaccessible.

CAUSE RACINE
Fléau de la dimensionnalité

100% Valide

IDQN (SKRL)

Deep Q-Network avec masque 11D

ACTIONS INVALIDES
0 (Sécurité totale)
Masquage strict des logits.

ARBITRAGE DE RÉCOMPENSE
-0,32 vs -0,02
Détour coûteux vs immobilité.

CAUSE RACINE
Passivité sécurisée (Reward Shaping)

Verrou Spatial

IPPO & MAPPO

Méthodes Acteur-Critique (CTDE / Indép.)

ACTIONS INVALIDES
~196 à 199 / 200 pas
Inférence stochastique non filtrée.

CONFLIT D'ALLÉE
Allée d'une case
Blocage face-à-face irréversible.

CAUSE RACINE
POSG sans canal de communication

Enseignement : Le masquage garantit la sécurité (IDQN), mais la coordination nécessite un canal de communication explicite ou la factorisation de valeur (QMIX).

Ce qu'on retient

1

L’apprentissage indépendant a des limites

Les agents apprennent sans coordination explicite. Les interactions entre robots entraînent des blocages et des actions invalides, malgré l'apprentissage individuel.

2

La représentation de l'environnement et les contraintes environnementales sont déterminantes

Le masquage des actions permet d'éviter les actions interdites, mais ne garantit pas la réussite des tâches ni la coordination entre robots.

3

La coordination reste le principal défi

Les agents doivent apprendre à coopérer en partageant l’espace et en évitant les conflits.

Pistes : MADDPG / QMIX, approches Dec-POMDP et planification MAPF pour améliorer la coordination et les déplacements des robots

